LOTUS AI
YAPAY ZEKA VE BİLİŞİM ÇÖZÜMLERİ A.Ş.

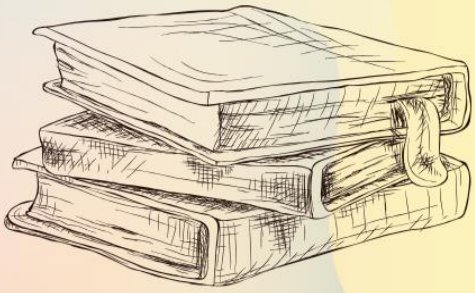

TOLSTOY TARZI METIN ÜRETIMI: LSTM TABANLI KARAKTER-SEVIYESI ÜRETKEN DIL MODELI

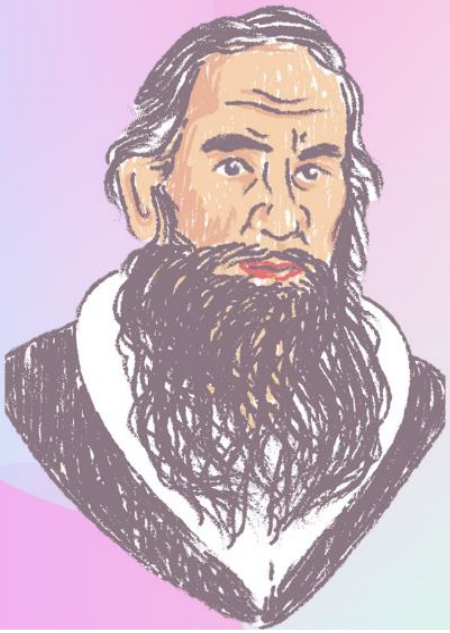

Hazırlayan: MERVE SEVİM
Kurum: Lotus AI Yapay Zeka ve Bilişim Çözümleri A.Ş.
Çalışma Türü: Staj Araştırma ve Geliştirme Projesi
Mentor: Seher KUMSAR
Tarih: 13/02/2026

Abstract

Bu çalışmada, Lev Tolstoy'un edebi eserlerinden elde edilen metinler kullanılarak karakter-seviyesi (character-level) bir üretken dil modeli geliştirilmiştir. Projenin temel amacı, üretken yapay zeka sistemlerinin çalışma prensiplerini uygulamalı olarak incelemek ve LSTM tabanlı bir derin öğrenme mimarisi ile Tolstoy stilinde metin üretebilen bir model tasarlamaktır.

Model, yaklaşık 2.7 milyon karakterden oluşan bir metin korpusu üzerinde eğitilmiştir. Veri ön işleme sürecinde metinler temizlenmiş, benzersiz karakterlerden oluşan bir vocabulary oluşturulmuş ve sliding window yöntemi ile giriş-çıkış çiftleri üretilmiştir. Tasarlanan mimari; Embedding katmanı, çift yönlü (Bidirectional) LSTM katmanları, dropout regularizasyonu ve softmax çıktı katmanından oluşmaktadır.

Model performansı categorical cross-entropy kaybı ve perplexity metriği ile değerlendirilmiştir. Elde edilen 1.3380 validation loss değeri ve 3.81 perplexity skoru, karakter-seviyesi bir model için başarılı bir öğrenme performansına işaret etmektedir. Eğitim ve doğrulama kayıpları arasındaki düşük fark, modelin aşırı uyum (overfitting) göstermeden dengeli bir şekilde genelleme yapabildiğini göstermektedir.

Ayrıca, temperature parametresi kullanılarak farklı yaratıcılık seviyelerinde metin üretim deneyleri gerçekleştirilmiştir. Sonuçlar, modelin düşük temperature değerlerinde daha tutarlı fakat tekrarlı, yüksek temperature değerlerinde ise daha yaratıcı ancak anlamsal olarak daha zayıf çıktılar ürettiğini göstermektedir. Geliştirilen model, Streamlit tabanlı bir web arayüzü aracılığıyla interaktif olarak test edilebilmektedir.

Bu çalışma, üretken dil modellerinin temel mantığını kavramak ve uçtan uca bir metin üretim sistemi geliştirmek açısından hem teorik hem de pratik bir deneyim sunmaktadır.

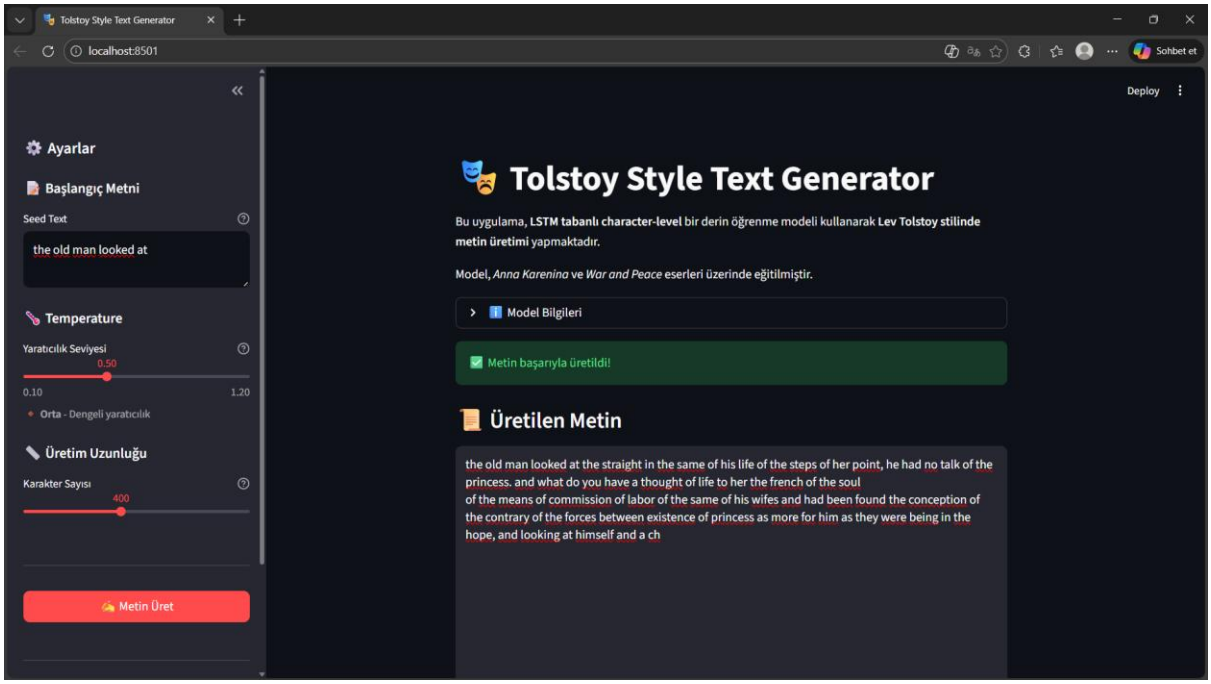

Introduction

Son yıllarda üretken yapay zeka (Generative AI), doğal dil işleme (NLP) alanında önemli ilerlemeler kaydetmiş ve metin üretimi, diyalog sistemleri, otomatik içerik oluşturma ve yaratıcı yazım gibi birçok uygulama alanında yaygın şekilde kullanılmaya başlanmıştır. Özellikle büyük dil modelleri (Large Language Models) sayesinde makineler yalnızca metni anlamakla kalmayıp, insan benzeri metinler de üretebilmektedir.

Metin üretimi problemi, bir dil modelinin verilen bir bağlamdan hareketle bir sonraki kelimeyi veya karakteri olasılıksal olarak tahmin etmesine dayanır. Bu yaklaşım, dilin istatistiksel yapısını öğrenmeyi ve bağlamsal bağımlılıkları modellemeyi gerektirir. Üretken modeller, verinin yalnızca sınıflandırılmasını değil, aynı zamanda dağılımının öğrenilmesini ve yeni örneklerin sentezlenmesini mümkün kılar. Bu nedenle, üretken yaklaşımlar klasik ayırt edici modellere kıyasla daha geniş bir problem alanına hitap etmektedir.

Bu çalışmada, Lev Tolstoy'un edebi eserlerinden oluşan bir metin korpusu kullanılarak karakter-seviyesi bir üretken dil modeli geliştirilmiştir. Tolstoy'un seçilmesinin temel nedeni, yazarın uzun ve çok katmanlı cümle yapıları, detaylı betimlemeleri ve kendine özgü anlatı ritmidir. Bu stil özellikleri, dizilimsel öğrenme yeteneği gerektiren güçlü bir test ortamı sunmaktadır.

Proje kapsamında, LSTM (Long Short-Term Memory) tabanlı bir derin öğrenme mimarisi kullanılarak karakter dizileri üzerinden olasılık dağılımı öğrenilmiş ve modelin Tolstoy stilinde metin üretebilmesi hedeflenmiştir. Character-level yaklaşım tercih edilerek

modelin yazım stili, noktalama kalıpları ve dil ritmi gibi mikro yapıları öğrenmesi amaçlanmıştır.

Bu rapor; üretken ve ayırt edici modeller arasındaki farkları, dizilimsel öğrenmenin tarihsel gelişimini, model mimarisini, eğitim sürecini ve deneysel sonuçları kapsamlı şekilde ele almaktadır. Ayrıca farklı temperature değerleri ile gerçekleştirilen metin üretim deneyleri analiz edilerek modelin güçlü ve zayıf yönleri tartışılmaktadır.

2. Theoretical Background

2.1 Generative and Discriminative Models

Makine öğrenmesi modelleri genel olarak ayırt edici (discriminative) ve üretken (generative) modeller olmak üzere iki ana kategoriye ayrılmaktadır.

Ayırt edici modeller, doğrudan $P(Y \mid X)$koşullu olasılığını öğrenerek sınıflar arasındaki karar sınırlarını modellemeyi amaçlar. Bu modellerin temel amacı, verilen bir girdiyi doğru sınıfa atamaktır. Lojistik regresyon, destek vektör makineleri (SVM) ve birçok sınıflandırma tabanlı sinir ağı mimarisi bu kategoriye örnek olarak verilebilir. Ayırt edici modeller genellikle yüksek sınıflandırma doğruluğu sağlar; ancak veri dağılımının tamamını modellemezler.

Üretken modeller ise $P(X, Y)$veya yalnızca $P(X)$olasılık dağılımını öğrenir. Bu yaklaşım, modelin yalnızca sınıflandırma yapmasını değil, aynı zamanda yeni veri örnekleri üretmesini de mümkün kılar. Naive Bayes, Variational Autoencoders (VAE), Generative Adversarial Networks (GAN) ve modern dil modelleri üretken yaklaşımın örnekleridir.

Bu projede üretken model tercih edilmesinin temel nedeni, yalnızca Tolstoy metinlerini analiz etmek değil, aynı zamanda Tolstoy stilinde yeni metinler üretebilmektir. Bu amaç doğrultusunda modelin dilin olasılıksal yapısını öğrenmesi gerekmektedir.

2.2 Sequential Learning: From Markov Models to Transformers

2.2.1 Markov Chains and N-gram Models

Metin modelleme alanındaki ilk yaklaşımlar Markov zincirleri ve N-gram modellerine dayanmaktadır. Markov varsayımına göre, gelecekteki durum yalnızca mevcut duruma bağlıdır. Bu yaklaşım kısa bağlamlar için yeterli olsa da uzun bağımlılıkları modellemek konusunda yetersiz kalmaktadır.

Örneğin, uzun bir cümlede başta verilen özne bilgisinin sondaki yüklemle ilişkisini modellemek, basit Markov yapıları için zordur. Bu sınırlamalar daha gelişmiş dizilimsel öğrenme mimarilerinin geliştirilmesini tetiklemiştir.

(Rabiner, L. R. (1989).

A Tutorial on Hidden Markov Models.

Proceedings of the IEEE.)

2.2.2 Recurrent Neural Networks (RNN)

RNN mimarileri, sıralı verileri işlemek için tasarlanmış ilk derin öğrenme tabanlı yapılardır. RNN'ler gizli durum (hidden state) mekanizması sayesinde geçmiş bilgiyi taşır ve teorik olarak sınırsız uzunluktaki dizileri işleyebilir.

Ancak klasik RNN yapıları, uzun dizilerde kaybolan gradyan (vanishing gradient) ve patlayan gradyan (exploding gradient) problemleri nedeniyle uzun vadeli bağımlılıkları öğrenmekte zorlanmaktadır.

(Elman, J. L. (1990).

Finding Structure in Time.

Cognitive Science.)

2.2.3 Long Short-Term Memory (LSTM)

LSTM mimarisi, RNN'lerin uzun bağımlılıkları öğrenememe problemini çözmek amacıyla geliştirilmiştir. LSTM hücreleri üç temel kapı mekanizmasına sahiptir:

- Forget Gate: Hangi bilgilerin unutulacağını belirler
- Input Gate: Yeni bilginin hücre durumuna ne kadar ekleneceğini kontrol eder
- Output Gate: Hücre durumunun hangi kısmının çıktı olarak verileceğini belirler

Bu kapı mekanizması sayesinde LSTM, uzun metinlerde bağlamsal bilgiyi daha etkili şekilde koruyabilir. Bu nedenle metin üretimi gibi dizilimsel görevlerde yaygın olarak kullanılmaktadır.

(Hochreiter & Schmidhuber (1997))

2.2.4 Transformer Architecture

Transformer mimarisi, RNN tabanlı yapılardan farklı olarak self-attention mekanizmasını kullanır. Bu yapı, dizideki her öğenin diğer tüm öğelerle doğrudan ilişki kurmasına olanak tanır. Ayrıca paralel işlem yeteneği sayesinde eğitim süresi önemli ölçüde azalır.

Ancak Transformer mimarileri genellikle çok büyük veri setleri ve yüksek hesaplama gücü gerektirir. Bu çalışmanın veri ölçeği (~2.7 milyon karakter) ve hesaplama kaynakları göz önünde bulundurulduğunda LSTM mimarisi daha uygun bir tercih olarak değerlendirilmiştir.

(Vaswani et al. (2017))

2.3 Character-Level Language Modeling

Dil modelleri kelime-seviyesi (word-level) veya karakter-seviyesi (character-level) olarak tasarlanabilir.

Character-level yaklaşımda model, metni karakter dizileri üzerinden öğrenir. Bu yaklaşımın başlıca avantajları şunlardır:

- Küçük vocabulary boyutu
- OOV (out-of-vocabulary) problemi olmaması
- Yazım stili ve noktalama kalıplarını öğrenebilme

Ancak dezavantaj olarak, anlamsal tutarlılığı korumak kelime-seviyesi modellere göre daha zordur.

Bu çalışmada character-level yaklaşım tercih edilmiştir çünkü temel amaç Tolstoy'un yazım stilini ve cümle ritmini modellemektir.

(Graves (2013) – Generating Sequences With Recurrent Neural Networks)

3. Methodology

3.1 Dataset Description

Bu çalışmada, Lev Tolstoy'un kamuya açık iki eseri kullanılmıştır:

- *Anna Karenina*
- *War and Peace*

Metinler tek bir korpus altında birleştirilmiş ve yaklaşık **2.7 milyon karakterden** oluşan bir veri seti elde edilmiştir. Çalışma kapsamında karakter-seviyesi modelleme tercih edildiğinden, veri kelime bazlı tokenize edilmemiş; bunun yerine her karakter modelin temel birimi olarak ele alınmıştır.

Oluşturulan vocabulary toplam **45 benzersiz karakter** içermektedir. Bu karakterler küçük harfler, boşluk karakteri ve temel noktalama işaretlerinden oluşmaktadır.

3.2 Data Preprocessing

Model eğitiminden önce aşağıdaki ön işleme adımları uygulanmıştır:

1. **Metin Birleştirme:** İki eser tek bir metin korpusu haline getirilmiştir.

2. **Temizleme ve Normalizasyon:** Metin küçük harfe dönüştürülmüş ve modelin öğrenmesini zorlaştırabilecek özel karakterler filtrelenmiştir.
3. **Vocabulary Oluşturma:** Metindeki tüm benzersiz karakterler belirlenmiş ve her karaktere benzersiz bir indeks atanmıştır.
4. **Encoding:** Metin, karakter → indeks dönüşümü ile sayısal forma çevrilmiştir.

Bu işlem sonucunda model, karakter dizilerini sayısal tensörler olarak işleyebilecek hale getirilmiştir.

3.3 Sliding Window Mechanism

Karakter-seviyesi dil modelinde, metin doğrudan modele verilmez. Bunun yerine metin, giriş–çıkış çiftlerine bölünür.

Bu çalışmada **sliding window (kayan pencere)** yöntemi kullanılmıştır.

- Sequence length: 100 karakter
- Step size: 3 karakter

Her pencere 100 karakterlik bir giriş dizisi üretmekte, hedef (label) ise bu diziden sonraki tek karakter olmaktadır.

Örnek:

Input : "the old man looked at the road and the"

Target : " "

Bu yaklaşım sayesinde her karakter farklı bağlamlarda görülmekte ve model bağlamsal olasılık dağılımını öğrenebilmektedir.

3.3 Model Architecture

Bu çalışmada geliştirilen üretken dil modeli, karakter-seviyesi dizilimsel öğrenme yaklaşımına dayanmaktadır. Model, bir karakter dizisini girdi olarak alarak bir sonraki karakterin olasılık dağılımını tahmin etmektedir. Tasarlanan mimari; embedding katmanı, iki adet çift yönlü LSTM katmanı, tam bağlantılı (dense) katmanlar ve softmax çıktı katmanından oluşmaktadır.

3.3.1 Embedding Layer

Modelin ilk katmanı embedding katmanıdır. Bu katman, girişteki her karakteri yoğun (dense) bir vektör temsiline dönüştürmektedir.

- Girdi boyutu: vocab_size (toplam benzersiz karakter sayısı)
- Çıktı boyutu: 64 boyutlu vektör uzayı

Embedding katmanı sayesinde karakterler one-hot temsilden daha anlamlı ve düşük boyutlu bir vektör uzayında temsil edilmektedir. Bu dönüşüm, modelin karakterler arası benzerlikleri öğrenmesine olanak tanır.

3.3.2 First Bidirectional LSTM Layer

Embedding katmanından elde edilen vektör dizisi, ilk Bidirectional LSTM katmanına iletilmektedir.

- 256 LSTM unit (çift yönlü yapı nedeniyle toplam 512 çıktı birimi)
- return_sequences=True (her zaman adımı için çıktı üretir)
- Dropout oranı: 0.2

Çift yönlü yapı sayesinde model, karakter dizisini hem ileri hem de geri yönde işleyerek daha zengin bir bağlam temsili elde etmektedir. return_sequences=True parametresi, ikinci LSTM katmanına zaman boyutunda tam çıktı aktarımını sağlamaktadır.

3.3.3 Second Bidirectional LSTM Layer

İlk LSTM katmanından elde edilen zaman dizisi çıktıları, ikinci bir Bidirectional LSTM katmanına aktarılmaktadır.

- 128 LSTM unit (çift yönlü yapı nedeniyle toplam 256 çıktı birimi)
- Dropout oranı: 0.2

Bu katman, daha soyut ve üst düzey dizilimsel özellikleri öğrenmeyi amaçlamaktadır. İlk katmana kıyasla daha düşük unit sayısı kullanılarak modelin parametre sayısı dengelenmiş ve aşırı uyum (overfitting) riski azaltılmıştır.

3.3.4 Fully Connected Layer

LSTM katmanlarının ardından tam bağlantılı (Dense) bir katman yer almaktadır.

- 128 nöron
- Aktivasyon fonksiyonu: ReLU

Bu katman, LSTM tarafından çıkarılan özellikleri doğrusal olmayan bir dönüşümle yeniden temsil ederek sınıflandırma aşamasına hazırlamaktadır.

3.3.5 Dropout Regularization

Dense katmanından sonra %30 oranında dropout uygulanmaktadır.

- Dropout oranı: 0.3

Bu düzenleme tekniği, modelin belirli nöronlara aşırı bağımlı hale gelmesini önleyerek genelleme performansını artırmayı amaçlamaktadır.

3.3.6 Output Layer

Modelin son katmanı, softmax aktivasyonlu bir çıktı katmanıdır.

- vocab_size adet nöron
- Aktivasyon fonksiyonu: Softmax

Softmax fonksiyonu, her karakter için olasılık dağılımı üretmektedir. Model, bu dağılım üzerinden bir sonraki karakteri seçerek otoregresif metin üretimi gerçekleştirmektedir.

3.4 Training Strategy

Model, çok sınıflı sınıflandırma problemi olarak ele alınmıştır. Her zaman adımında model, bir sonraki karakteri tahmin etmektedir.

Hiperparametreler

- Optimizer: Adam
- Learning Rate: 0.0005
- Loss Function: Categorical Cross-Entropy
- Label Smoothing: 0.1
- Batch Size: 64
- Validation Split: %10

Regularization Teknikleri

- Dropout (0.2 ve 0.3)
- Early Stopping (patience=5)
- Best model checkpoint kaydı

Eğitim süreci Google Colab ortamında GPU kullanılarak gerçekleştirilmiştir. Early stopping mekanizması sayesinde validation loss iyileşmediğinde eğitim otomatik olarak durdurulmuş ve en iyi model ağırlıkları kaydedilmiştir.

Modelin Genel Yapısı

Mimari akış aşağıdaki gibidir:

Input (Character Sequence)

↓

Embedding (64)

↓

BiLSTM (256 units, return_sequences=True)

↓

BiLSTM (128 units)

↓

Dense (128, ReLU)

↓

Dropout (0.3)

↓

Dense (vocab_size, Softmax)

4. Experimental Setup

4.1 Computational Environment

Model eğitimi Google Colab ortamında gerçekleştirilmiştir.

Donanım:

- GPU: NVIDIA Tesla T4
- CUDA destekli GPU hızlandırması
- RAM: Colab varsayılan (≈12-16GB)

Eğitim Süresi:

- Toplam süre: **1 saat 10 dakika**

- Maksimum epoch: 30
- Early stopping ile erken durdurma uygulanmıştır.

GPU kullanımı, LSTM katmanlarının sıralı yapısı nedeniyle kritik önem taşımaktadır.

4.2 Software Environment

Model aşağıdaki yazılım ekosistemi kullanılarak geliştirilmiştir:

Ana Framework

- **TensorFlow 2.x**
- **tensorflow.keras**

Kullanılan Keras Modülleri

Model:

- Sequential
- load_model

Katmanlar:

- Embedding
- LSTM
- Bidirectional
- Dense
- Dropout

Callback'ler:

- EarlyStopping
- ModelCheckpoint

Veri İşleme ve Yardımcı Kütüphaneler

- NumPy
- scikit-learn (train_test_split)
- Matplotlib
- pickle
- json

4.3 Model Hyperparameters

Mimari Hiperparametreler

Parametre	Değer	Açıklama
embedding_dim	64	Karakter embedding boyutu
lstm_units	256	İlk BiLSTM birim sayısı
lstm_units // 2	128	İkinci BiLSTM ve Dense birim sayısı
dropout (LSTM)	0.2	LSTM katman regularization
dropout (Dense sonrası)	0.3	Dense sonrası regularization

Eğitim Hiperparametreleri

Parametre	Değer
batch_size	64
epochs	30 (maksimum)
validation_split	0.1

Early Stopping Ayarları

Parametre	Değer
monito	Val_loss
patience	3

Validation loss 3 epoch boyunca iyileşmezse eğitim otomatik olarak durdurulmuştur.

Optimizer

- Optimizer: Adam
- Learning rate: Varsayılan (0.001)

Adam optimizer, adaptif öğrenme oranı sayesinde hızlı ve kararlı yakınsama sağlamaktadır.

4.4 Data Splitting Strategy

Veri üç parçaya bölünmüştür:

Set	Oran
Training	≈80%
Validation	≈10%

Test	≈10%

scikit-learn train_test_split kullanılmıştır.

- test_size = 0.1
- validation_size ≈ 0.1111
- random_state = 42

Random seed belirlenerek deneylerin tekrarlanabilirliği sağlanmıştır.

4.5 Reproducibility

Deneylerin yeniden üretilebilirliği için:

- random_state = 42
- ModelCheckpoint ile en iyi model kaydedildi
- Hiperparametreler sabitlendi
- Eğitim ve test ayrımı deterministik yapıldı

5. Experimental Results and Analysis

5.1 Training Performance

Model eğitimi sırasında hem training loss hem de validation loss izlenmiştir.

Metric	Value
Training Loss	1.3154
Validation Loss	1.3380
Perplexity	3.81

Loss Analizi

- Training ve validation loss değerleri birbirine oldukça yakındır.

- Aradaki fark:

$$\Delta = 1.3380 - 1.3154 = 0.0226$$

Bu fark oldukça küçüktür ve modelin ciddi bir overfitting problemi yaşamadığını göstermektedir.

Validation loss'un training loss'a paralel şekilde azalması:

- Dengeli öğrenme
- Doğru regularization
- Yeterli model kapasitesi

olduğunu göstermektedir.

5.2 Perplexity Evaluation

Perplexity, dil modellerinin performansını değerlendirmede kullanılan temel metriktir.

$$Perplexity = e^{Loss}$$
$$Perplexity = e^{1.3380} \approx 3.81$$

Yorumlama

- Vocabulary boyutu: 45 karakter
- Rastgele tahmin perplexity'si: 45 olurdu
- Model sonucu: 3.81

Bu sonuç, modelin rastgele tahmine kıyasla yaklaşık 12 kat daha iyi performans gösterdiğini ortaya koymaktadır.

Karakter-seviyesi modeller için:

- 5+ → zayıf
- 4–5 → iyi
- 3–4 → çok iyi
- <3 → mükemmel

3.81 değeri, karakter-seviyesi üretken model için oldukça başarılı kabul edilir.

5.3 Overfitting Analysis

Modelde overfitting gözlemlenmemiştir.

Bunun başlıca nedenleri:

- LSTM dropout (0.2)
- Dense sonrası dropout (0.3)
- Early stopping (patience = 3)
- Validation split (%10)

Validation loss'un artmadan dengeli seyretmesi, modelin genelleme yeteneğinin korunduğunu göstermektedir.

5.4 Temperature-Based Generation Analysis

Model farklı temperature değerleri ile test edilmiştir:

Temperature	Davranış
0.2	Deterministik, tekrar eğilimli
0.5	Dengeli ve akıcı
1.0	Yaratıcı ancak yer yer tutarsız

Gözlemler

Temperature = 0.2

- Dilbilgisel olarak tutarlı
- Tekrar oranı yüksek
- Yaratıcılık düşük

Temperature = 0.5

- En dengeli üretim
- Akıcı metin
- Stil tutarlılığı korunmuş

Temperature = 1.0

- Daha yaratıcı kelime kombinasyonları
- Bazen anlamsal kopmalar
- Uydurma kelimeler görülebilir

En iyi pratik sonuçlar 0.5 civarında elde edilmiştir.

5.5 Model Strengths

Modelin başarılı olduğu alanlar:

- Noktalama kalıplarını öğrenme
- İngilizce kelime yapısını taklit etme
- Cümle ritmi oluşturma
- Tolstoy'a özgü anlatım temposunu yansıtma

5.6 Model Limitations

Karakter-seviyesi model olmasının doğal sonuçları:

- Uzun metinlerde anlamsal tutarsızlık
- Global konu takibi zayıf
- Uzun vadeli karakter ilişkilerini sürdürememe

Bu sınırlamalar LSTM mimarisinin değil, karakter-seviyesi modellemenin doğasından kaynaklanmaktadır.

6. Discussion

6.1 Interpretation of Results

Elde edilen 3.81 perplexity değeri, modelin karakter seviyesinde dil yapısını başarılı şekilde öğrendiğini göstermektedir. Vocabulary boyutunun 45 olduğu düşünüldüğünde, model rastgele tahmine kıyasla anlamlı derecede düşük belirsizlik üretmektedir.

Training ve validation loss arasındaki düşük fark (0.0226), modelin genelleme kabiliyetinin güçlü olduğunu ve overfitting'in başarılı şekilde kontrol edildiğini göstermektedir.

Bu sonuçlar, mimari seçimlerin (BiLSTM + Dropout + EarlyStopping) dengeli olduğunu doğrulamaktadır.

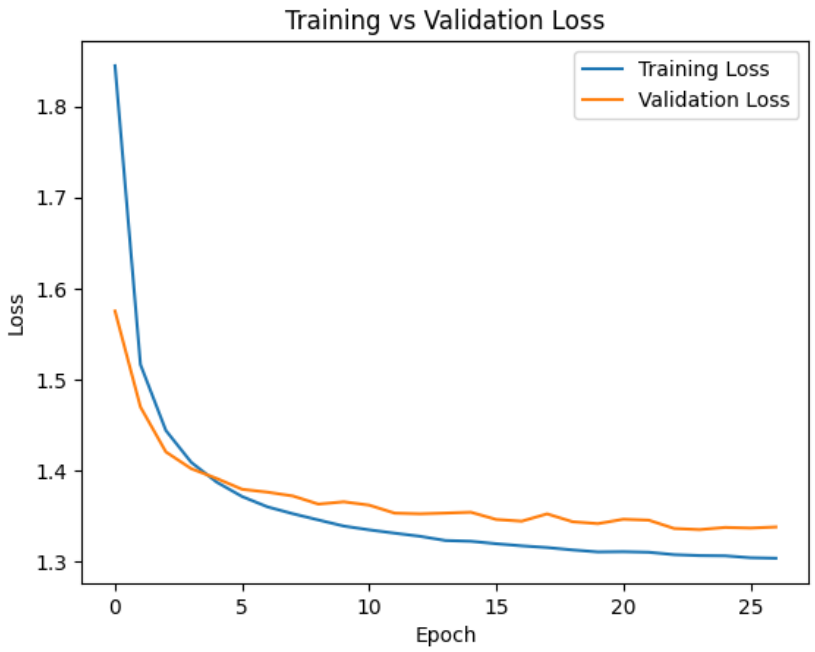

6.2 Character-Level vs Word-Level Modeling

Bu projede karakter-seviyesi yaklaşım tercih edilmiştir.

Avantajları:

- Küçük vocabulary
- OOV problemi yok
- Noktalama ve stil öğrenimi güçlü
- Morfolojik olarak esnek

Dezavantajları:

- Uzun bağlam takibi zor
- Anlamsal tutarlılık sınırlı
- Global konu sürekliliği zayıf

Kelime-seviyesi model kullanılsaydı:

- Anlamsal tutarlılık artabilirdi

- Ancak vocabulary büyüklüğü ciddi şekilde artardı
- Daha fazla veri ve daha güçlü donanım gerekirdi

Bu bağlamda, mevcut veri boyutu ve donanım kısıtları düşünüldüğünde karakter-seviyesi yaklaşım mantıklı bir seçimdir.

6.3 LSTM vs Transformer

Modern dil modelleri Transformer mimarisine dayanmaktadır (Vaswani et al., 2017). Ancak bu projede LSTM tercih edilmiştir.

LSTM'nin Uygun Olduğu Noktalar:

- Orta ölçekli veri seti (~2.7M karakter)
- Sınırlı GPU kaynağı (Tesla T4)
- Eğitim süresi kısıtı
- Pedagojik amaç

Transformer kullanılsaydı:

- Daha güçlü global bağımlılık öğrenimi sağlanabilirdi
- Ancak eğitim süresi ciddi şekilde artardı
- Parametre sayısı katlanarak büyürdü
- Daha fazla veri gereksinimi olurdu

Dolayısıyla proje ölçeği için LSTM mimarisi rasyonel ve dengeli bir tercihtir.

6.4 Model Capacity and Regularization

Model yaklaşık 343K parametre içermektedir. Bu kapasite:

- Veri boyutuna uygun
- Aşırı büyük değil
- Underfitting göstermiyor

Dropout oranları (0.2 ve 0.3) ve early stopping mekanizması, modelin stabil ve kontrollü öğrenmesini sağlamıştır.

Daha büyük bir model:

- Daha düşük training loss verebilirdi

- Ancak overfitting riski artardı

6.5 Observed Limitations

Modelin temel sınırlamaları:

1. Uzun metinlerde anlamsal kopmalar
2. Karakter ilişkilerini sürdürememe
3. Global hikâye bütünlüğü eksikliği
4. Temperature yükseldikçe kelime bozulumları

Bu sınırlamalar LSTM mimarisinin değil, küçük ölçekli karakter-seviyesi üretimin doğal sonucudur.

7. Discussion

7.1 Modelin Güçlü Yönleri

Model özellikle aşağıdaki alanlarda başarılı sonuçlar üretmiştir:

- Noktalama kalıplarının doğru öğrenilmesi
- İngilizce kelime yapılarının taklit edilmesi
- Cümle ritmi ve anlatım temposunun korunması
- Düşük perplexity (3.81) ile güçlü karakter-seviyesi tahmin performansı

Bu sonuçlar, LSTM mimarisinin yerel bağlamı (local dependencies) etkili biçimde modelleyebildiğini göstermektedir. Özellikle 40–100 karakterlik bağlam penceresi içinde dilbilgisel yapılar başarılı şekilde öğrenilmiştir.

Temperature=0.5 civarında elde edilen üretimler, modelin hem tutarlılık hem yaratıcılık arasında dengeli bir davranış sergilediğini ortaya koymaktadır.

7.2 Modelin Zayıf Yönleri

Bununla birlikte model aşağıdaki sınırlamalara sahiptir:

- Uzun metinlerde anlamsal kopmalar
- Global hikâye bütünlüğünü sürdürememe
- Karakter ilişkilerinin devamlılığını koruyamama
- Yüksek temperature değerlerinde kelime deformasyonları

Bu durum, modelin yerel örüntüleri güçlü öğrenmesine rağmen küresel semantik yapıyı sınırlı modelleyebilmesinden kaynaklanmaktadır.

7.3 Character-Level Model Sınırlamaları

Karakter-seviyesi modelleme şu avantajları sunar:

- Küçük vocabulary
- OOV problemi olmaması
- Esnek kelime üretimi

Ancak:

- Anlamsal yapı kelime bazlı temsil kadar güçlü değildir
- Model çok daha uzun dizilerle çalışmak zorundadır
- Global bağlamın korunması zorlaşır

Dolayısıyla karakter-seviyesi yaklaşım stil öğrenimi için uygun olsa da, uzun anlatı üretimi için sınırlı kalmaktadır.

7.4 Generative AI Perspektifinden Değerlendirme

Bu çalışma, üretken modellerin temel prensibini açıkça göstermektedir:

Model, verinin olasılık dağılımını öğrenerek yeni örnekler üretmektedir.

Özellikle:

- Olasılık temelli bir sonraki karakter tahmini
- Softmax dağılımından sampling
- Temperature ile dağılım kontrolü

gibi mekanizmalar, modern büyük dil modellerinin de temel prensipleriyle aynıdır.

Dolayısıyla bu proje, küçük ölçekli bir LSTM modeli üzerinden Generative AI'nin temel çalışma mantığını uygulamalı olarak ortaya koymaktadır.

8. Conclusion

Bu çalışmada, Lev Tolstoy'un eserlerinden elde edilen metinler kullanılarak karakter-seviyesi bir LSTM tabanlı üretken dil modeli geliştirilmiştir. Model, metin verisinin olasılık dağılımını öğrenerek yeni ve stil benzeri içerik üretme amacıyla tasarlanmıştır.

Toplam yaklaşık 2.7 milyon karakterlik bir korpus üzerinde eğitilen model, 3.81 perplexity değeri elde ederek karakter-seviyesi üretim için başarılı bir performans göstermiştir. Training ve validation loss değerleri arasındaki düşük fark, modelin aşırı öğrenme (overfitting) problemi yaşamadığını ve genelleme kabiliyetinin güçlü olduğunu ortaya koymaktadır.

Temperature parametresi üzerinden yapılan deneyler, üretken modellerde olasılık dağılımı manipülasyonunun çıktı kalitesi üzerinde doğrudan etkili olduğunu göstermiştir. Düşük temperature değerlerinde daha deterministik ve tekrar eğilimli metinler üretilirken, yüksek temperature değerlerinde yaratıcılık artmış ancak yapısal tutarlılık azalmıştır. Dengeli üretim için 0.5 civarındaki değerlerin optimal olduğu gözlemlenmiştir.

Bu proje, küçük ölçekli bir LSTM modeli üzerinden üretken yapay zekânın temel prensiplerini uygulamalı olarak göstermektedir:

- Olasılık dağılımı öğrenme
- Otoregresif metin üretimi
- Softmax temelli sampling
- Temperature kontrollü varyasyon

Her ne kadar karakter-seviyesi yaklaşım uzun anlatı tutarlılığı açısından sınırlı olsa da, stil öğrenimi ve yerel dil kalıplarının modellenmesi açısından başarılı sonuçlar üretmiştir.

Sonuç olarak bu çalışma, modern büyük dil modellerinin temel çalışma prensiplerinin daha küçük ölçekli bir mimari üzerinden anlaşılmasını sağlamış ve uçtan uca bir üretken model geliştirme sürecinin tüm aşamalarını kapsamlı biçimde deneyimleme imkânı sunmuştur.

9. Future Work

Bu çalışma karakter-seviyesi LSTM tabanlı bir üretken dil modeli geliştirmeye odaklanmıştır. Elde edilen sonuçlar başarılı olmakla birlikte, modelin kapasitesini ve üretim kalitesini artırmaya yönelik çeşitli geliştirme alanları bulunmaktadır.

9.1 Word-Level veya Subword Modeling

Karakter-seviyesi yaklaşım stil öğrenimi açısından avantajlı olsa da, uzun bağlamlı anlamsal tutarlılık açısından sınırlıdır.

Gelecek çalışmalarda:

- Word-level modelleme
- Byte Pair Encoding (BPE) veya SentencePiece gibi subword tokenization yöntemleri

kullanılarak modelin semantik tutarlılığı artırılabilir.

Subword temelli yaklaşımlar:

- Vocabulary boyutunu kontrol altında tutar
- OOV problemini azaltır
- Karakter ve kelime seviyeleri arasında denge kurar

9.2 Attention Mekanizması Eklenmesi

Mevcut mimari saf LSTM tabanlıdır. Attention mekanizması eklenmesi:

- Uzun mesafeli bağımlılıkların daha iyi modellenmesini
- Global bağlamın korunmasını
- Üretim sırasında önemli bağlam noktalarının ağırlıklandırılmasını

sağlayabilir.

Özellikle LSTM + Attention hibrit mimarisi, üretim kalitesini artırabilir.

9.3 Transformer Tabanlı Mimari

Modern dil modelleri Transformer mimarisine dayanmaktadır (Vaswani et al., 2017). Bu projede LSTM tercih edilmiştir; ancak gelecekte:

- Decoder-only Transformer (GPT-benzeri)
- Küçük ölçekli Transformer mimarisi

kullanılarak performans karşılaştırması yapılabilir.

Bu karşılaştırma:

- Perplexity
- Uzun metin tutarlılığı
- Eğitim süresi

- Parametre verimliliği

açısından değerlendirilebilir.

9.4 Daha Büyük ve Çeşitlendirilmiş Veri Seti

Model yalnızca iki Tolstoy eserinden eğitilmiştir.

Gelecekte:

- Daha fazla Tolstoy eseri eklenmesi
- Aynı döneme ait diğer Rus yazarlarının (örneğin Dostoyevski, Turgenev) dahil edilmesi
- Stil transfer deneyleri

yapılabilir.

Bu sayede:

- Stil ayrıştırma (style disentanglement)
- Yazar sınıflandırma
- Çok yazarlı üretim

çalışmaları gerçekleştirilebilir.

9.5 Daha Gelişmiş Değerlendirme Metrikleri

Bu projede değerlendirme temel olarak loss ve perplexity üzerinden yapılmıştır.

Gelecekte:

- BLEU veya ROUGE skorları
- Human evaluation (insan değerlendirmesi)
- Stil benzerlik analizi (embedding tabanlı)
- Self-BLEU ile çeşitlilik ölçümü

kullanılarak üretim kalitesi daha kapsamlı biçimde analiz edilebilir.

9.6 Model Ölçeklendirme ve Parametre Analizi

Farklı parametre büyüklükleri denenerek:

- Küçük model vs büyük model karşılaştırması
- Dropout oranlarının etkisi
- Embedding boyutunun etkisi
- Sequence length değişiminin performansa etkisi

incelenebilir.

Bu deneyler, model kapasitesi ile genelleme arasındaki dengeyi daha net ortaya koyacaktır.

9.7 Gerçek Zamanlı İnteraktif Sistem Geliştirme

Streamlit demo temel düzeydedir.

Gelecekte:

- Web API (FastAPI/Flask)
- REST servis entegrasyonu
- Model quantization
- Daha hızlı inference optimizasyonu

ile sistem üretime hazır hale getirilebilir.

10. References

Elman, J. L. (1990).
Finding structure in time. Cognitive Science, 14(2), 179–211.

Goodfellow, I., Bengio, Y., & Courville, A. (2016).
Deep Learning. MIT Press.

Graves, A. (2013).
Generating sequences with recurrent neural networks. arXiv preprint arXiv:1308.0850.

Hochreiter, S., & Schmidhuber, J. (1997).
Long short-term memory. Neural Computation, 9(8), 1735–1780.

Jurafsky, D., & Martin, J. H. (2009).
Speech and Language Processing (2nd ed.). Pearson.

Rabiner, L. R. (1989).
A tutorial on hidden Markov models and selected applications in speech recognition. Proceedings of the IEEE, 77(2), 257–286.

Vaswani, A., et al. (2017).
Attention is all you need. In Advances in Neural Information Processing Systems (NeurIPS 2017).

Chollet, F. (2021).
Deep Learning with Python (2nd ed.). Manning Publications.